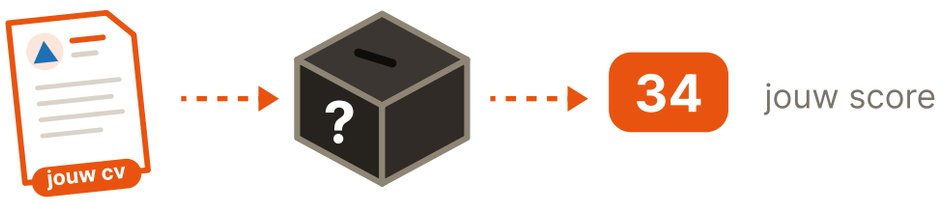
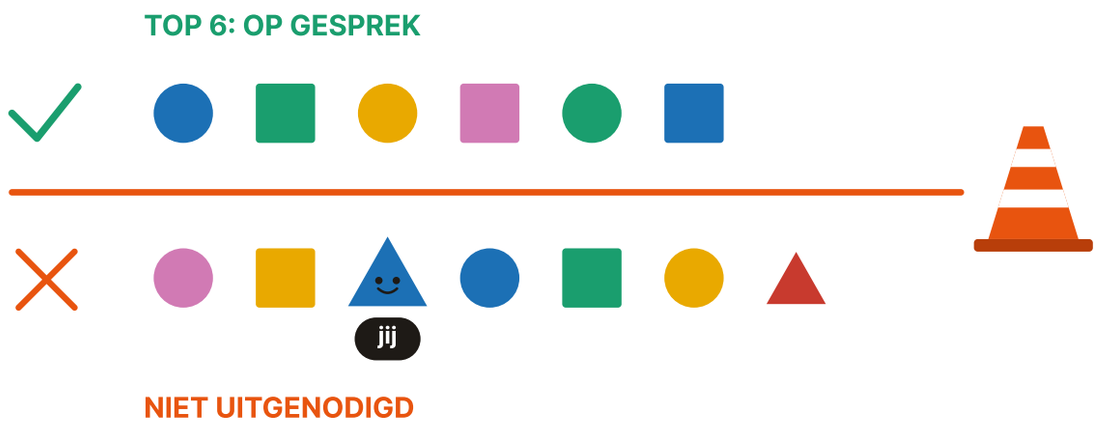
LEES MIJ EERST

Demo eerlijkheid en algoritmes

De zwarte doos

Te veel cv's, te weinig tijd. Dus kocht een bedrijf een **algoritme:** het geeft **elk cv een score** en zet iedereen op een rij. **De top 6 mag op gesprek.**





Waarom heet dat een ‘black box’?

Je ziet wat erin gaat en wat eruit komt, maar wat ertussen gebeurt, is te ingewikkeld om te volgen. De doos leerde zelf, uit de **aanwervingen van vroeger**. Kozen mensen vroeger (vaak zonder het te beseffen) liever cirkels? Dan leert de doos dat ook, en doet ze het gewoon verder. En ze is **niet perfect**: ze heeft maar in 7 op de 10 gevallen gelijk.

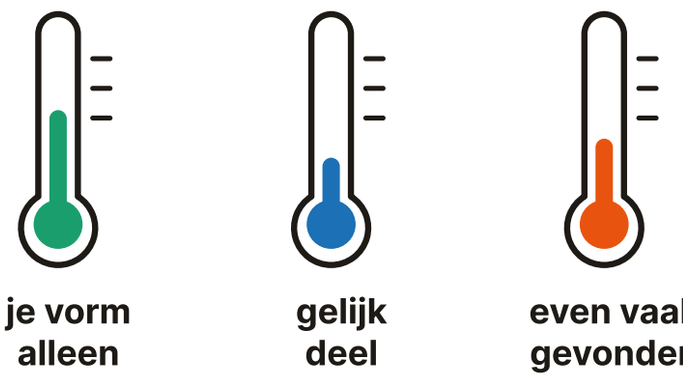


Niet kijken, ook wel **fairness through unawareness** genoemd, is niet genoeg.
Ook als niemand de doos je vorm vertelt, kan ze die afleiden uit de rest van je cv. Daarom meten we.

De thermometers

Hoe weet je of het algoritme eerlijk is? Daar bestaan tests voor, *fairness metrics. Ze werken als een **thermometer**: een afwijkende waarde* betekent dat er iets scheef zit.

Er bestaan **meer dan 50** testen. Wij tonen er drie. Geeft een thermometer afwijkingen aan, dan kan het bedrijf het algoritme **bijsturen**.
Het probleem: elke thermometer kijkt naar iets anders, en je krijgt ze nooit allemaal tegelijk in orde. Iemand moet dus kiezen welke het zwaarst meetelt. Vandaag kies jij dat.



1 · Je vorm alleen

counterfactual fairness

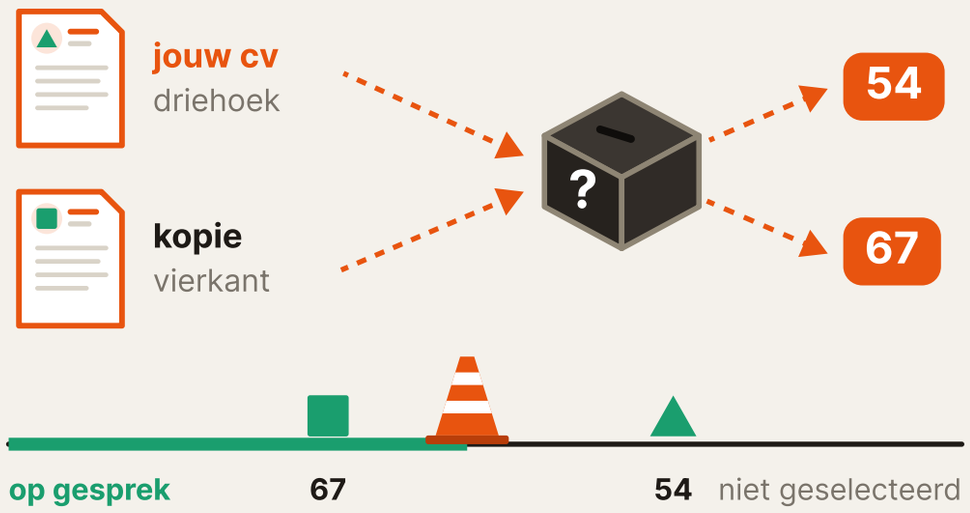
Krijg je hetzelfde resultaat als je enkel je vorm of je grootte zou veranderen?

ZO MEET JE HET

1. Maak een **kopie** van je cv.
2. Verander op de kopie **alleen je vorm of je grootte**, en wat daar rechtstreeks uit volgt.
3. Laat het algoritme **beide** cv's scoren. Verschillen ze, dan let de doos toch op je vorm.

ZO STUUR JE BIJ

De doos wordt aangepast tot het originele cv en de kopie **ongeveer dezelfde score krijgen, voor iedereen.**



GOED OM TE WETEN

> Kijkt naar elke persoon apart, niet naar groepen. Een vorm kan dus nog altijd minder vaak op gesprek mogen. En wat ‘mee verandert’ met je vorm, is vaak een discussie op zich.

2 · Gelijk deel

statistical parity

Krijgt elke vorm evenveel interviews?

ZO MEET JE HET

Deze regel zorgt dat **elke vorm een even grote kans** heeft op een interview. Tel per vorm: hoeveel solliciteerden er, en hoeveel mogen op gesprek? Is dat deel niet ongeveer gelijk, dan scoort het algoritme slecht op deze thermometer.

ZONDER BIJSTUREN

cirkels — 4 van 4 (100%)

vierkanten — 2 van 8 (25%)

BIJGESTUURD

cirkels — 2 van 4 (50%)

vierkanten — 4 van 8 (50%)

ZO STUUR JE BIJ

Maak **een rij per vorm** en nodig uit elke rij **hetzelfde percentage** uit. Elke vorm krijgt dan een eigen kegel, die met een andere score overeen kan komen.

GOED OM TE WETEN

> Dit kijkt niet enkel naar wie geschikt is: soms blijft iemand met een hogere score thuis. Handig als je denkt dat de oude aanwervingen zelf scheef zaten.

3 · Even vaak gevonden

equal opportunity

Vindt het algoritme geschikte mensen even vaak per vorm?

ZO MEET JE HET

Neem sollicitanten **van vroeger**, van wie je nu weet of ze echt geschikt waren (bv. een evaluatie na 6 maanden). Kijk **enkel naar de geschikte** rij: wie werd terecht gekozen, en wie werd onterecht gemist? Tel de verhoudingen per vorm.

	✓ Gesprek	✗ Geen gesprek
Geschikt	**Terecht gekozen**	**Gemist**
Niet geschikt	Onterecht gekozen	Terecht afgewezen

ZONDER BIJSTUREN · ALLEEN WIE ECHT GESCHIKT WAS

cirkels — 4 van 4 (100%)

vierkanten — 2 van 4 (50%)

BIJGESTUURD

cirkels — 3 van 4 (75%)

vierkanten — 3 van 4 (75%)

ZO STUUR JE BIJ

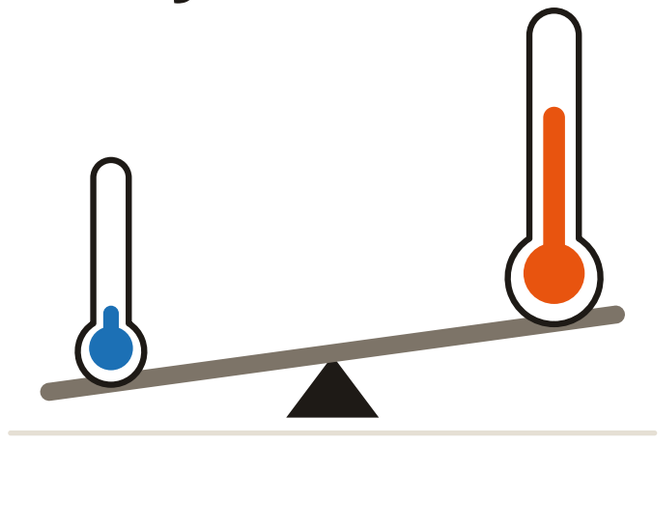
Verschuif de kegel **per vorm** tot elke vorm hetzelfde percentage van de geschikte kandidaten krijgt.

GOED OM TE WETEN

> Je hebt gegevens van vroeger nodig, die ook vertekend kunnen zijn. Maar vooral: hoe bepalen we wat ‘geschikt’ betekent?

Ze kunnen niet altijd allemaal in orde zijn.

Stel: vroeger bleken **6 van de 8 cirkels** geschikt, maar maar **2 van de 8 vierkanten. Er zijn 6 plekken.**



- **‘Gelijk deel’ wil 3 cirkels en 3 vierkanten.** Dan moet er minstens één vierkant door dat niet geschikt was, terwijl er geschikte cirkels thuisblijven.
- **‘Even vaak gevonden’ wil bij beide vormen hetzelfde deel van de geschikten:** ongeveer 4 à 5 cirkels en 1 à 2 vierkanten.
- En **‘je vorm alleen’**? De twee andere regels geven elke vorm een eigen kegel. Dan verandert je uitkomst soms wel als je vorm verandert.

Welke je voorrang geeft, is een keuze over wat jij eerlijk vindt. In de app kies je daarom telkens tussen twee thermometers: **welke moet volgens jou altijd in orde blijven?**

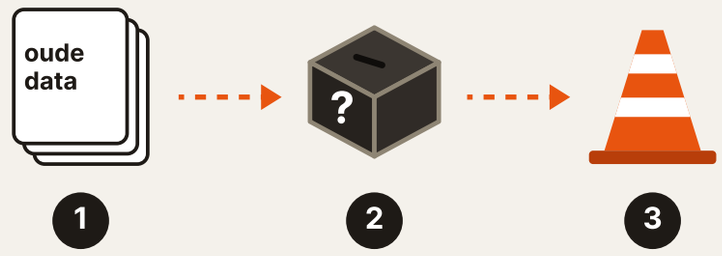
IN DE PRAKTIJK

Van vormen naar mensen

In het echt gaat het natuurlijk niet over rode cirkels of gele vierkantjes, maar dezelfde principes gelden voor kenmerken die je wél kent:

De vorm & grootte die je kreeg	**gender, leeftijd, nationaliteit**
De kleur die je koos	**opleiding, hobby's, vriendenkring**
Verborgen ‘geschikt’	**er na een jaar nog werken, een positieve evaluatie**

Waar kan je bijsturen?



1. **Vóór: de oude data rechtzetten,** bv. voorbeelden van weinig aangenomen vormen zwaarder laten meetellen.
2. **Tijdens: het algoritme leert met een extra regel:** ‘hou deze thermometer in orde’.
3. **Na: het algroitme blijft, maar de kegel schuift op**, bv. per vorm op een andere score.

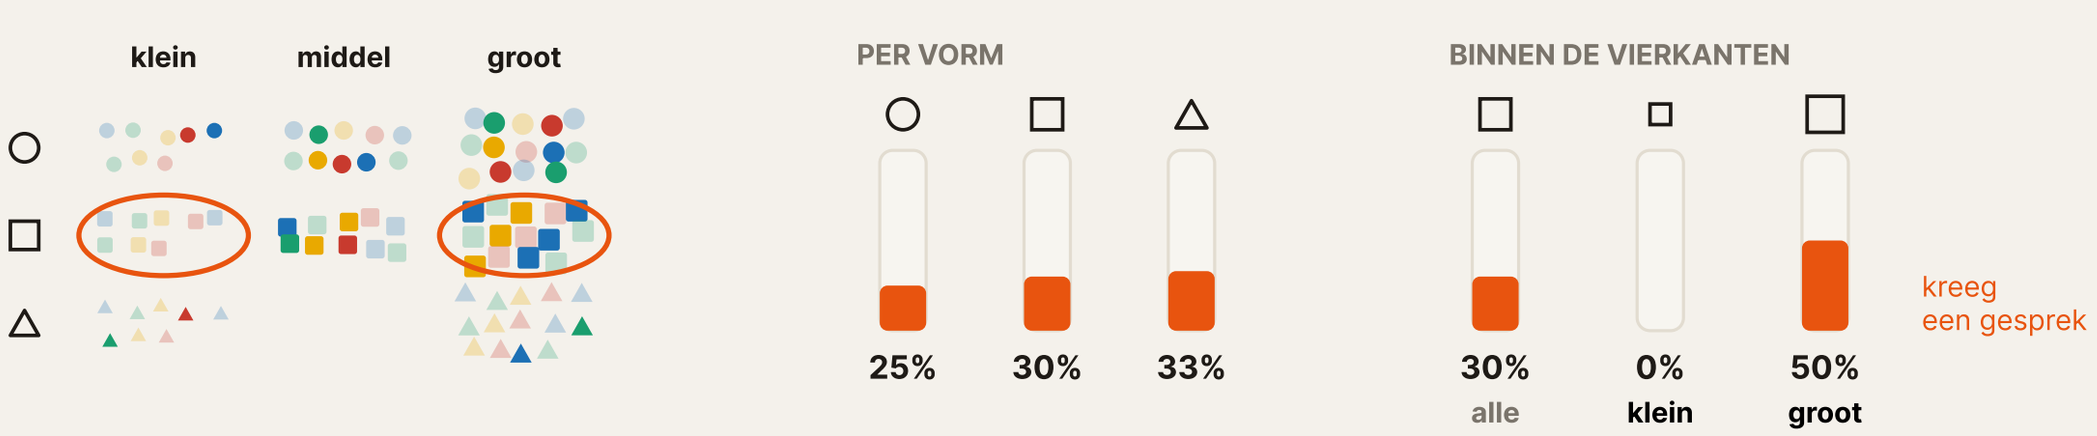
HET HOEKJE WAAR NIEMAND KEEK

Je bent meer dan één groep.



De thermometers keken slechts naar één ding: je vorm. Maar je bent ook groot, en je koos blauw. **Je zit in al die groepen tegelijk.**

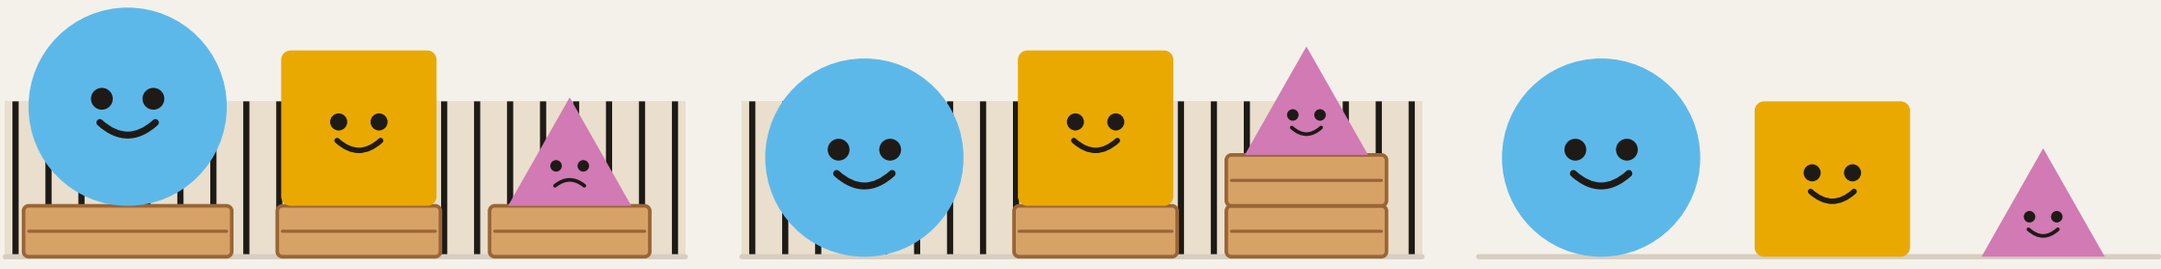
Neem 100 sollicitanten en zet ze per vorm én grootte bij elkaar, met ‘gelijk deel’ als regel. **Per vorm lijkt het eerlijk**: elke vorm kreeg interviews naar verhouding. **Maar binnen de vierkanten** kregen 10 van de 20 grote een gesprek, tegenover 0 van de 15 kleine.



Dit heet **intersectionaliteit**: je hoort bij meerdere groepen tegelijk, en waar ze kruisen, kan een metriek je missen.

De regel deed meer dan meten.

Een thermometer meet alleen maar. Maar ‘gelijk deel’ en ‘even vaak gevonden’ veranderden ook wie op gesprek mocht: scoorde een vorm laag, dan kreeg die een duwtje omhoog.



Gelijkheid equality

Iedereen krijgt hetzelfde kistje, zoals het onaangepaste algoritme dezelfde regel gebruikt voor iedereen. Klinkt eerlijk, maar de kleinste kan nog steeds niet over het hek kijken.

Gelijkwaardigheid equity

Iedereen krijgt de steun die nodig is. Nu kan iedereen over het hek kijken. Zo werkten ‘gelijk deel’ en ‘even vaak gevonden’.

Rechtvaardigheid justice

Het hek gaat weg. Dan heeft niemand nog een kistje nodig. Maar hoe krijg je dat hek weg?

ENKEL EERLIJK SORTEREN OF HERSTELLEN?

Die lage scores komen ergens vandaan.

Het algoritme leerde van oude aanwervingen. Sommige vormen kregen lang minder kansen, en dat zit nu in de cijfers. Eerlijk sorteren verdeelt de interviewplekken van vandaag opnieuw. Aan wat scheefgroeide, verandert het niets.

> De kistjes helpen over het hek kijken. Maar **het hek staat er nog.**

Een andere vraag: herstel.

Sommige onderzoekers vinden eerlijk sorteren niet genoeg. Hun vraag is niet ‘wie mag er vandaag bij?’, maar ‘wie werd benadeeld, en hoe maken we dat goed?’ Bijvoorbeeld: hebben twee kandidaten exact dezelfde kwalificaties, dan gaat wie uit de benadeelde groep komt voor. Alleen dan.

> Dit heet **rechtvaardigheid** (justice): de oorzaak wegwerken, zodat op termijn niemand nog een kistje nodig heeft.

Gebeurt dit echt?

Ja. Algoritmes helpen beslissen over sollicitaties, leningen, verzekeringen en uitkeringen. Een bekend voorbeeld: Amazon stopte met een cv-algoritme omdat het vrouwen lager scoorde. De **Europese AI-Act** noemt **AI voor aanwervingen ‘hoog risico’: zulke systemen moeten onder meer op vooroordelen gecontroleerd worden.**
Maar welke thermometer (= ‘metriek’) telt, kiezen de ontwikkelaars van algoritmes nu meestal. Ons doel is dat mensen over wie beslist wordt dat mee kunnen kiezen. Feedback over de duidelijkheid is dus altijd welkom!

DEZE DEMO IS GEMAAKT DOOR

SMIT
VUB · imec

AUGMENT
KU Leuven · imec

Vragen? Feedback?
→ an.jacobs@vub.be, anna.verheyden@kuleuven.be
Deze workshop volgen als groep?
→ an.jacobs@vub.be

Het zelf organiseren

Om het zelf te organiseren heb je nodig:

- **Wifi**
- Voldoende **toestellen** om op deel te nemen (gsm's, laptops, of tablets).
  Je vindt de app op https://fairness-demo-fti.vercel.app/
- OPTIONEEL: **tafels** met de fysieke opstelling op, **blokjes** als 'persona', **kaartjes**, **stempels**

Relevante links

De web app:
https://fairness-demo-fti.vercel.app/

De knoppen om te stemmen wat eerlijk is, op volgorde:
- https://fairness-demo-fti.vercel.app/tablet/bare_box
- https://fairness-demo-fti.vercel.app/tablet/counterfactual
- https://fairness-demo-fti.vercel.app/tablet/parity
- https://fairness-demo-fti.vercel.app/tablet/opportunity

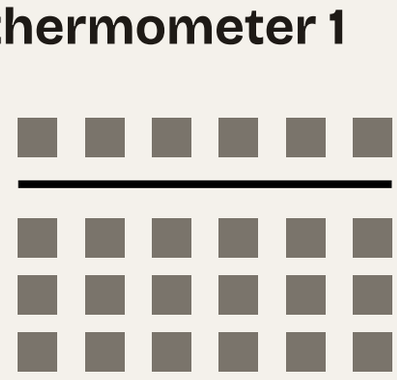
(wachtwoord 'fti-demo')

Persona

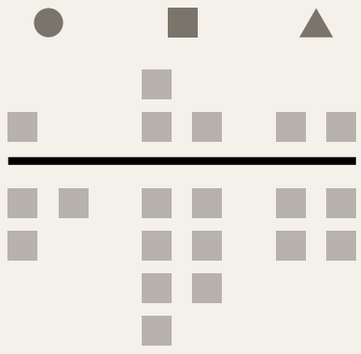
Vierkanten	klein:	5
	groot:	5
Cirkels	klein:	2
	groot:	2
Driehoeken	klein:	3
	groot:	3

Tafelopstelling

Het algoritme, thermometer 1

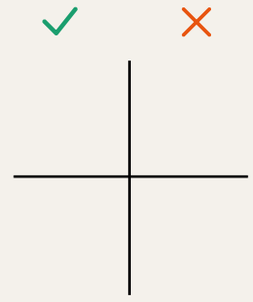


Thermometer 2



Het aantal personen per vorm verschilt, daarom hebben bv. vierkanten meer plaatsen

Thermometer 3



De rangschikking volgt dezelfde vorm als thermometer 2, maar nu tellen enkel de bovenste twee cellen mee.

Kaartjes

Na elke selectie mag een deelnemer stempelen of ze geselecteerd zijn om op interview te komen of niet.
Op het einde hangen deelnemers dit kaartje op een bord dat in twee gedeeld is: ze hangen het aan de linkerkant als ze eerlijk sorteren zonder herstel verkiezen, rechts als ze herstel wel belangrijk vinden. Op de achterkant kan je eventueel extra vragen toevoegen.

